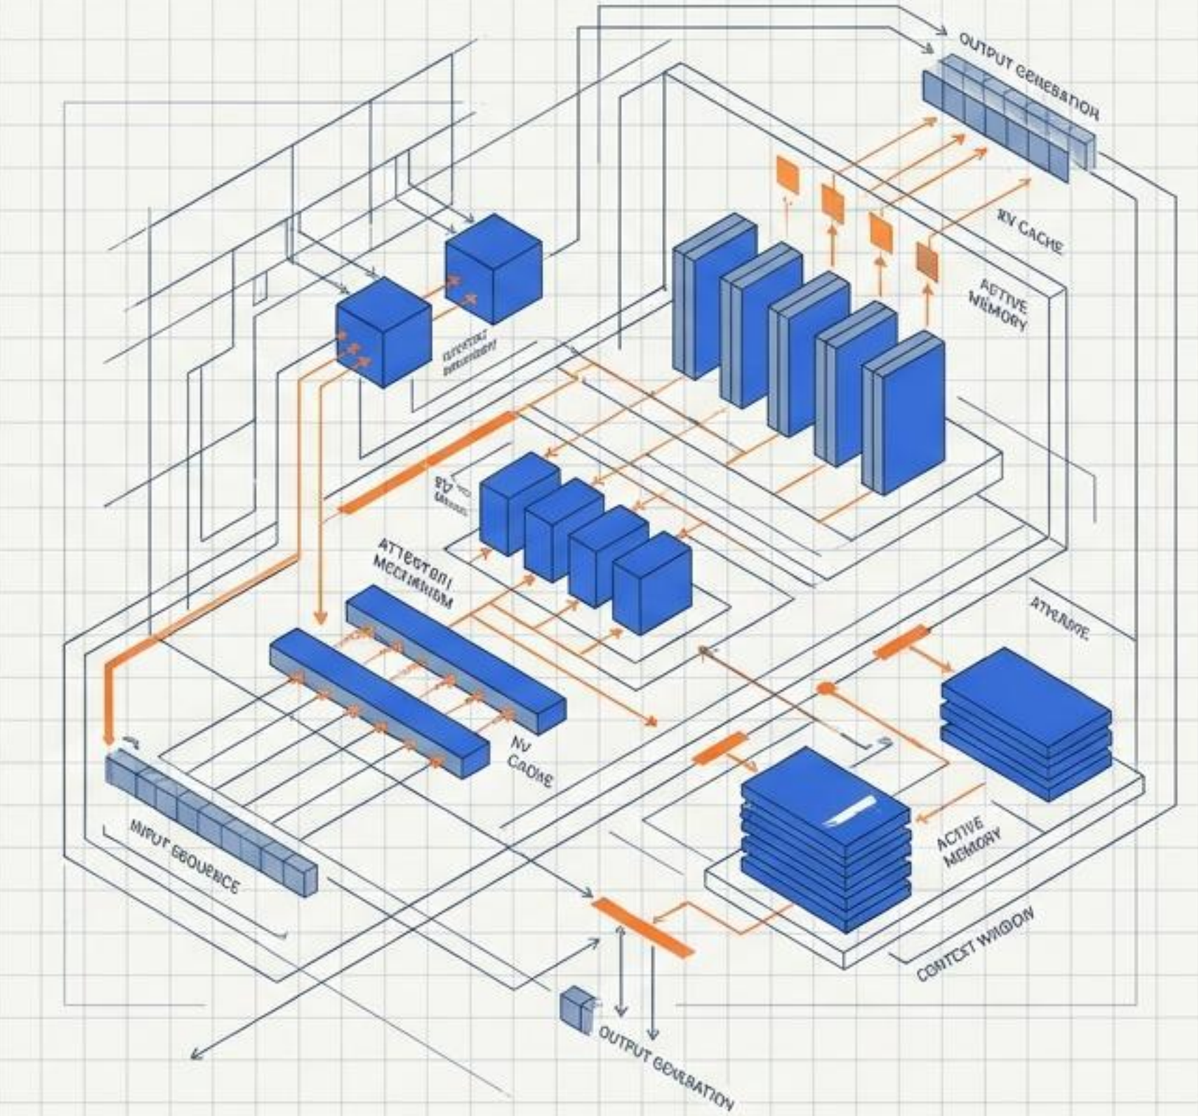
Context Engineering:

The Architecture of LLM Attention and Memory

大規模言語モデルにおけるコンテキスト管理のアーキテクチャと実装戦略



Gemini Notebook

パラダイムシフト：「プロンプト」から「コンテキスト」へ

Prompt Engineering（従来の視点）



焦点

「正しい言葉」を見つけること

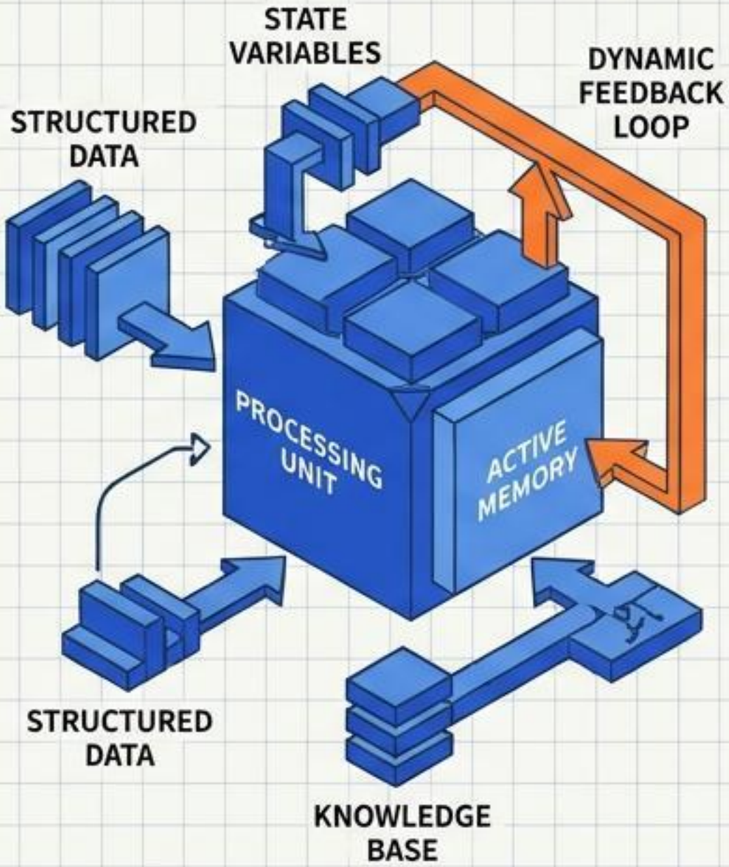
特徴

静的、非構造化、単発のタスク

限界

コンテキスト長が増加すると破綻する

Context Engineering（次世代の視点）



焦点

情報の「アーキテクチャ」と有限リソースの管理

特徴

動的、状態管理（ステートフル）、長期稼働エージェント

戦略

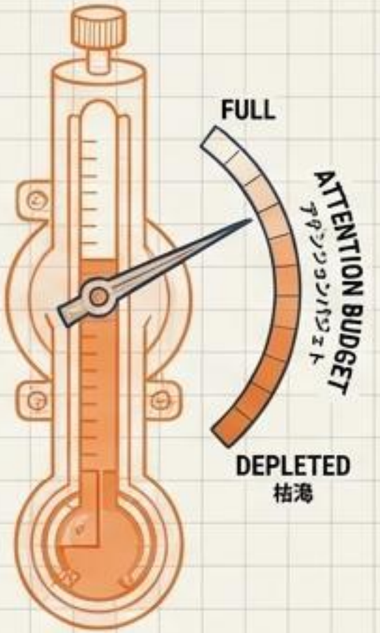
LLMを「テキスト生成器」ではなく「制約のある計算システム」として扱う

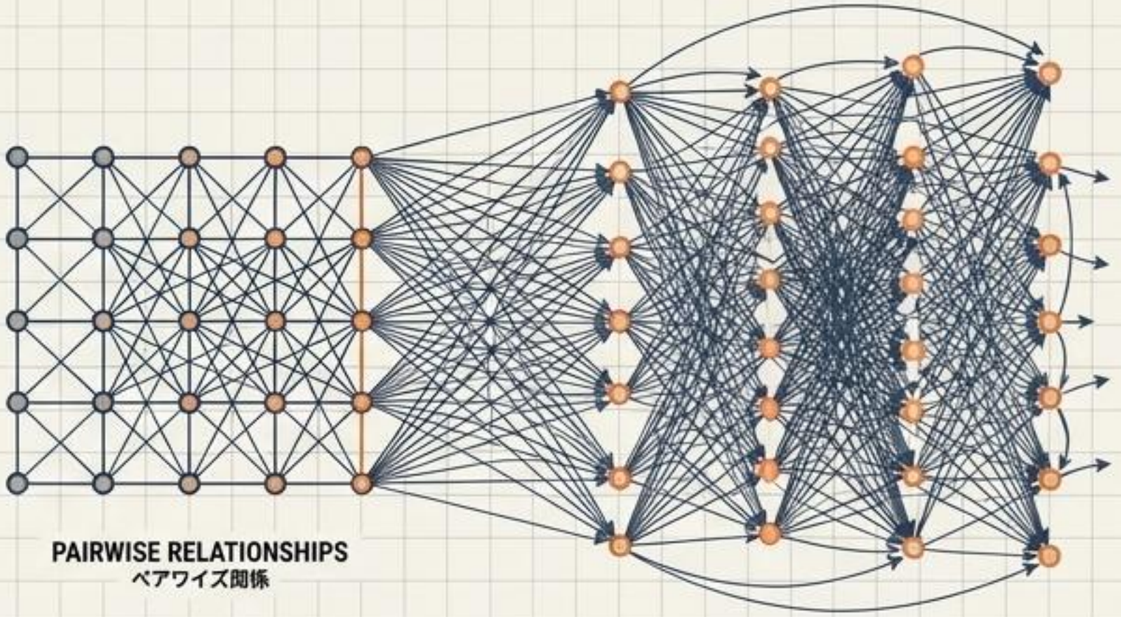
Gemini Notebook

LLMの物理的制約：アテンションバジェット

Transformerアーキテクチャは、コンテキスト内のすべてのトークンが他のすべてのトークンとペアワイズの関係を構築します。入力が増加するとと、モデルの「注意力」は物理的に枯渇します。

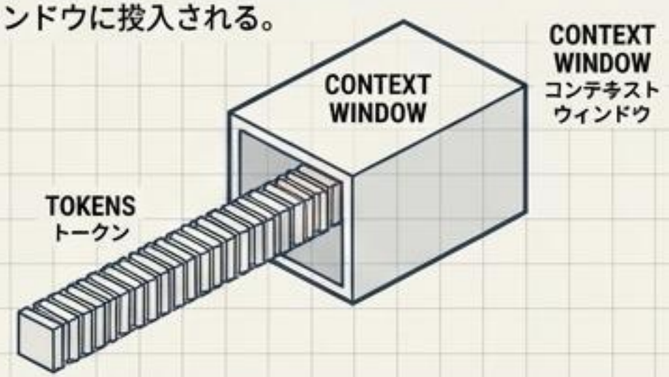






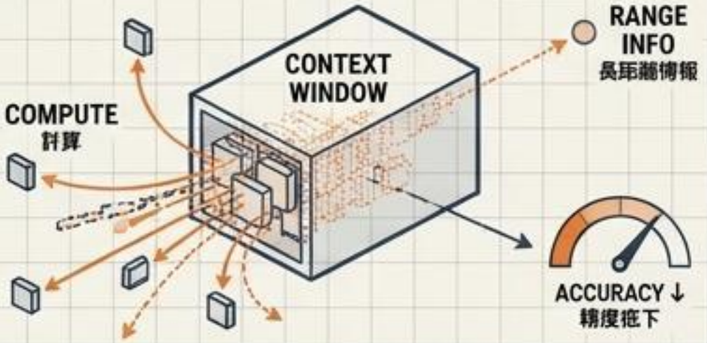
1. トークンの増加

数万〜数百万のトークンがコンテキストウィンドウに投入される。



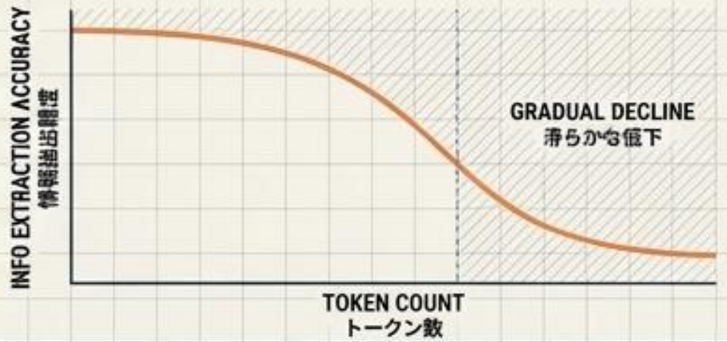
2. 予算の枯渇

計算リソースが分散し、長距離の推論や情報検索の精度が低下する。



3. パフォーマンスの境界

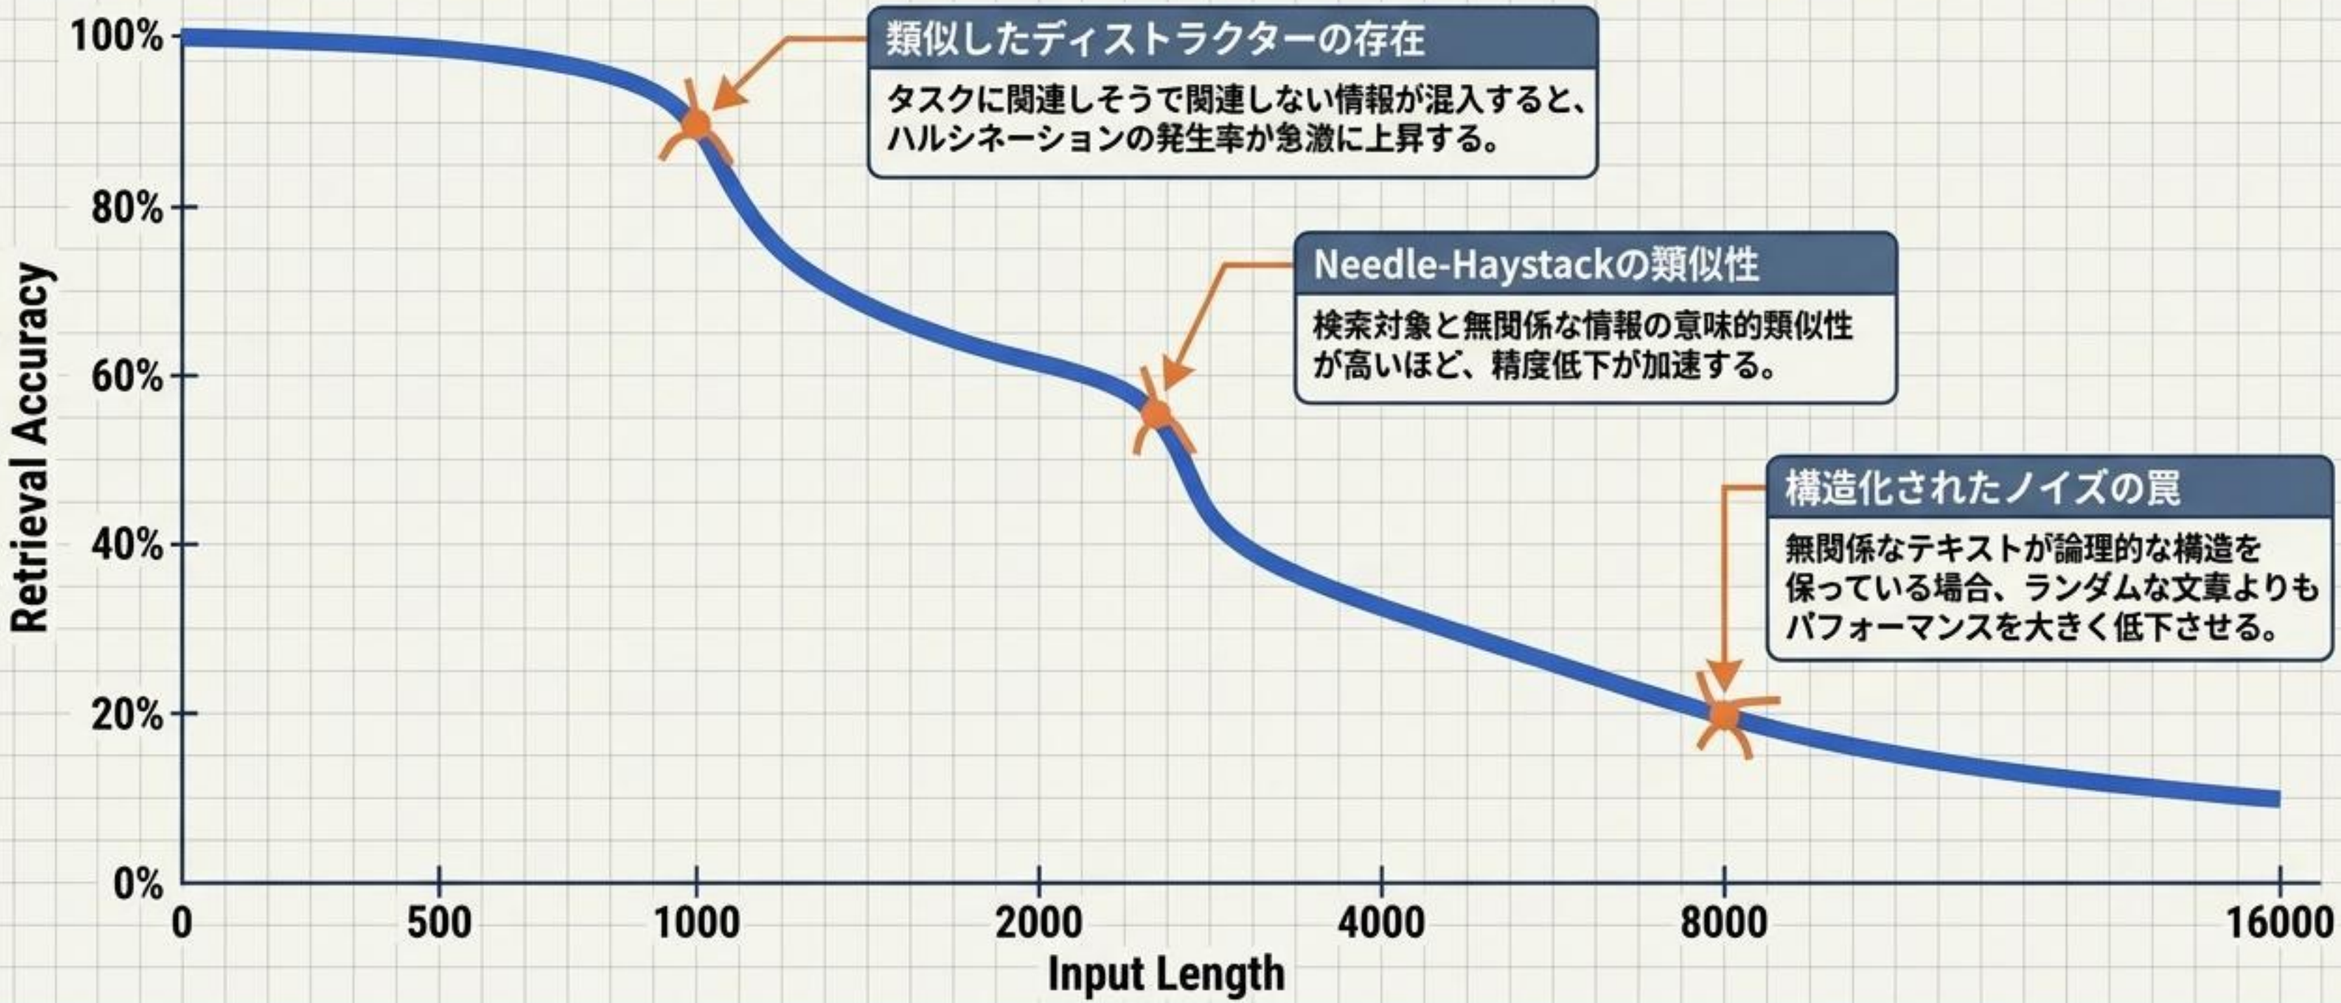
完全に機能停止するのではなく、情報抽出の精度が滑らかに、しかし確実に低下していく。



Gemini Notebook

コンテキストの病理１：Context Rot（文脈の腐敗）

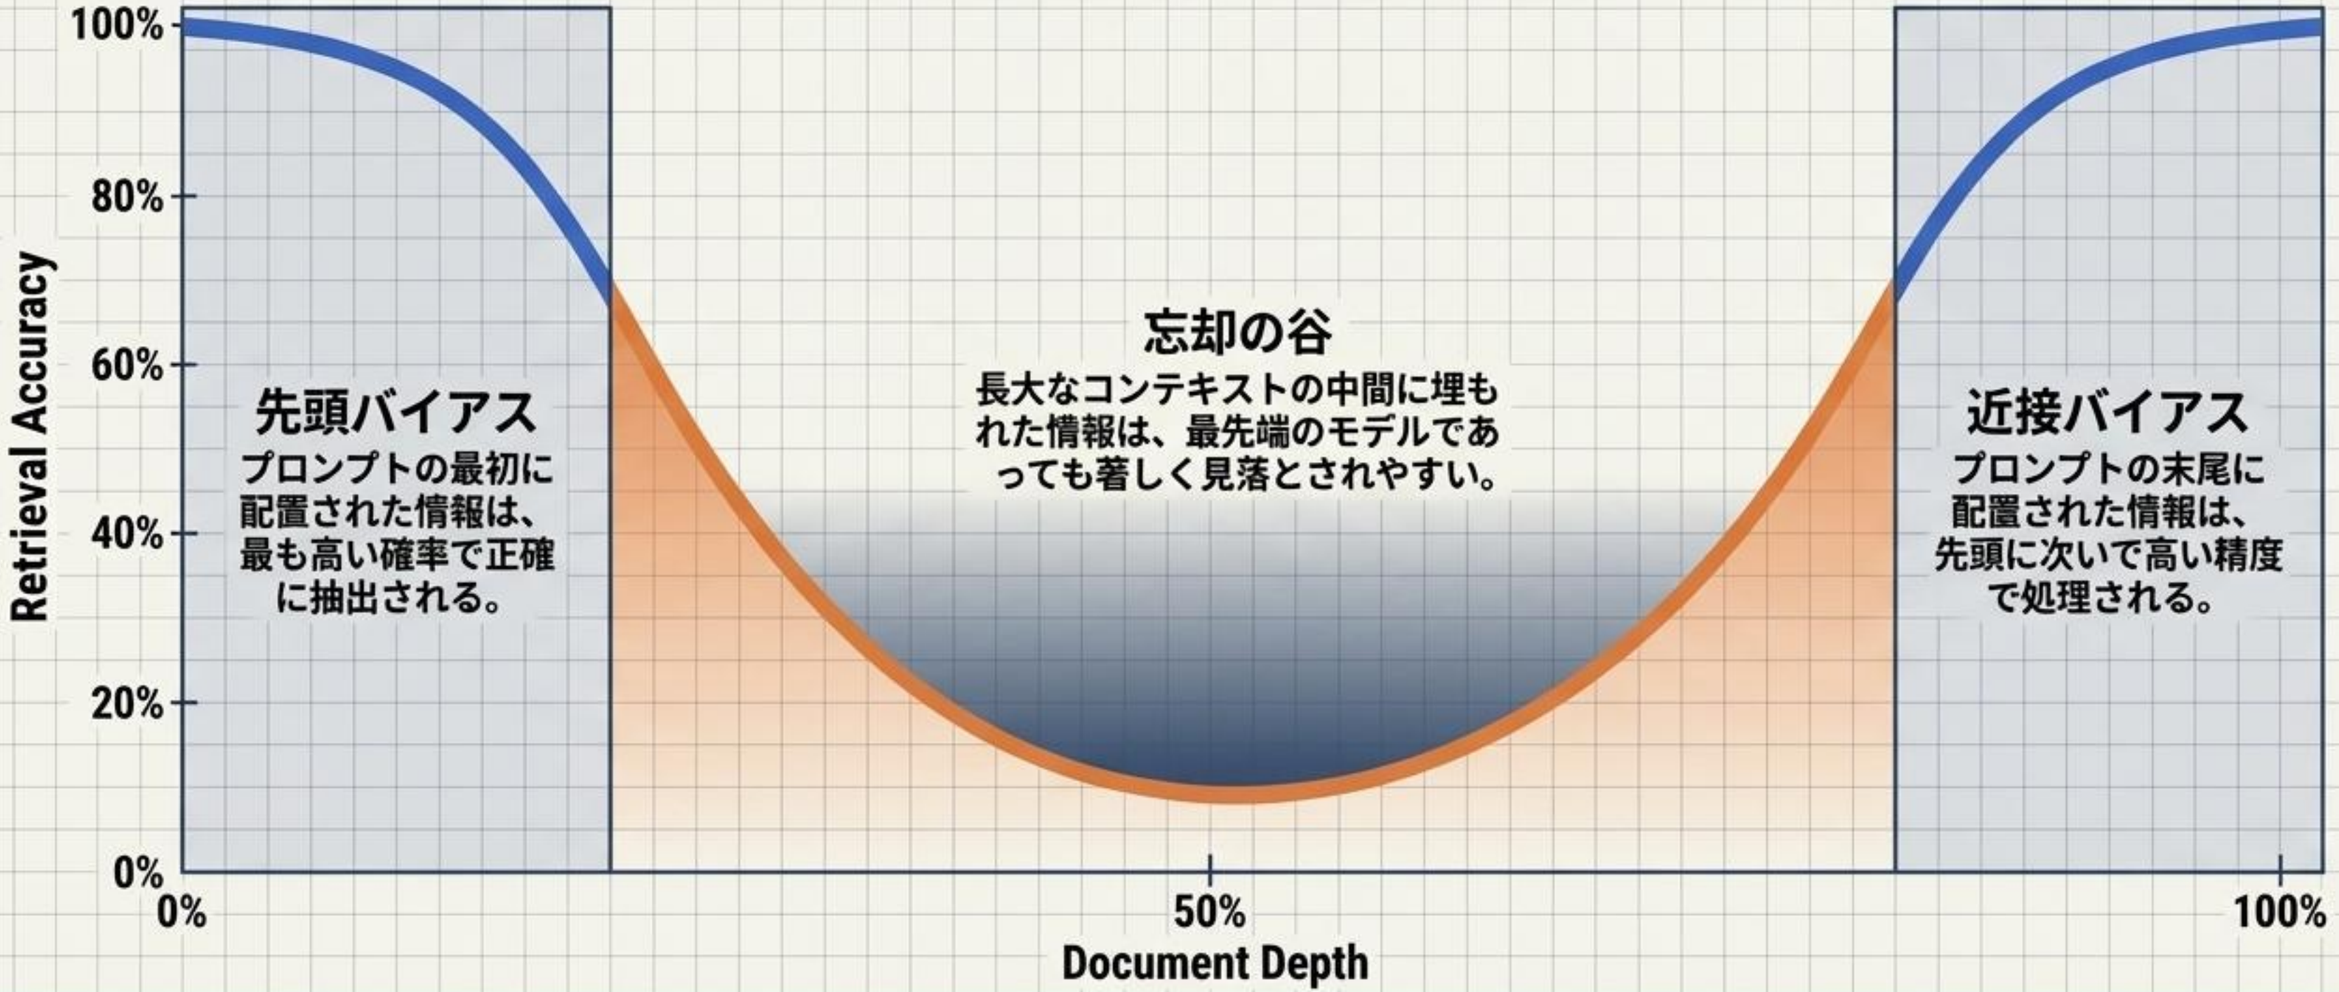
入力トークンス数が増加するにつれて、単純な検索タスクであってもLLMのパフォーマンスは非均一に低下 (腐敗) する。



Gemini Notebook

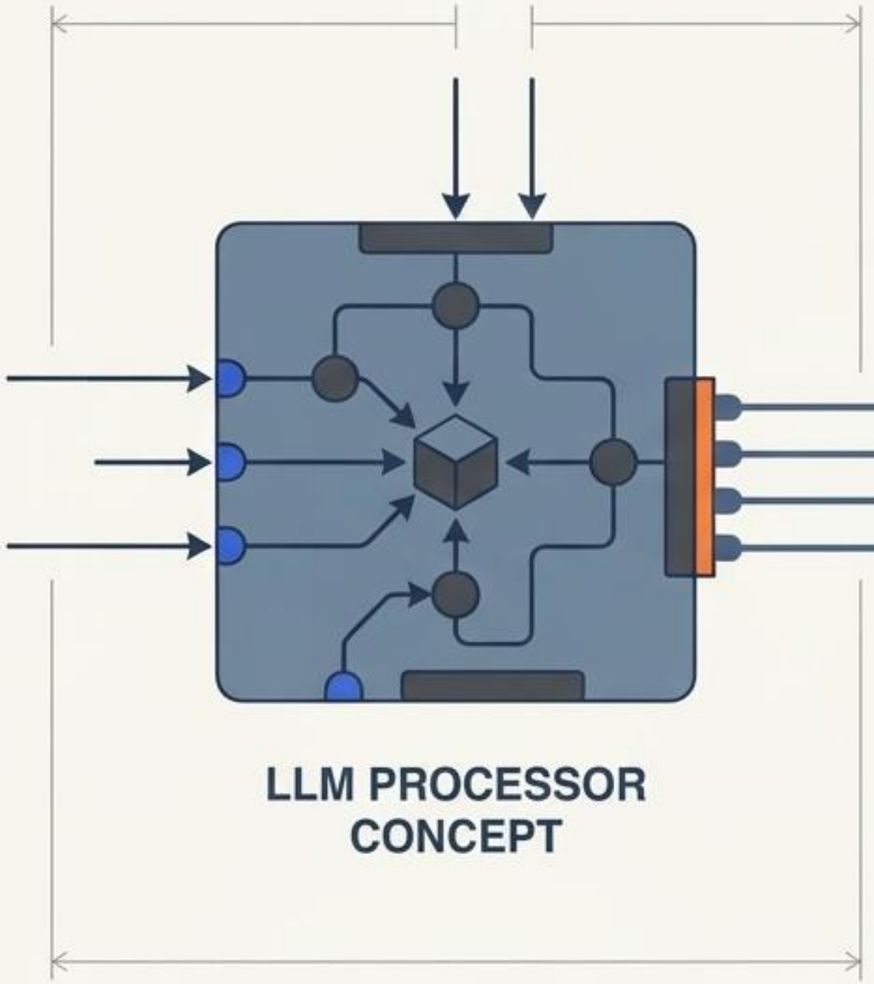
コンテキストの病理 2：Lost in the Middle

情報がコンテキストウィンドウの「どこ」に配置されるかが、検索精度を決定的に左右する。



Gemini Notebook

統合パラダイム：オペレーティングシステムとしてのLLM

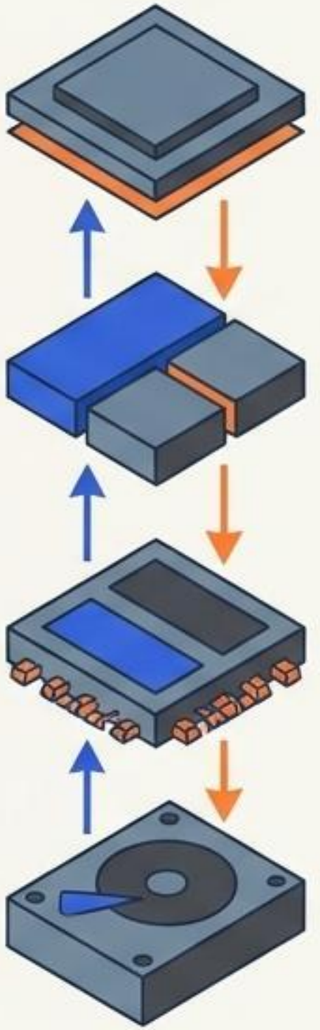


LLM Attention

Prompt Caching

Context Window

External DBs



CPU
(中央処理装置)
限られたサイクルでデータを処理する有限の計算リソース。

L1/L2 Cache
(キャッシュメモリ)
頻繁にアクセスされる静的データの高速かつ低コストな参照。

RAM
(物理メモリ)
高速だが容量に制限があり、揮発性を持つアクティブな作業空間。

Hard Disk
(外部ストレージ)
大容量で永続的な記憶領域。

Gemini Notebook

最適化レイヤー 1：Prompt Caching のメカニズム

モデルが入力トークンを処理する際の中間状態（Key-Valueテンソル）を保存し、同一のプレフィックスを持つ後続のリクエストで再利用する技術。

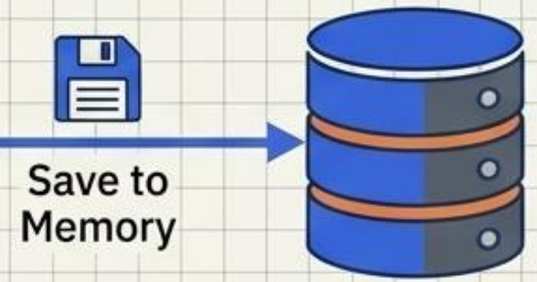
静的プレフィックス

APIツール定義、システム指示、リファレンスドキュメント

ここまでのハッシュが一致すれば、計算をスキップしキャッシュを読み込む

部分的なプレフィックス

進行中の会話履歴も自動的にキャッシュポイントとして認識される



動的サフィックス

最新のユーザー入力

毎回のAPIコールで変化する。この部分のみが新規に計算される

Gemini Notebook

キャッシュヒット率を最大化するプロンプト構造

アンチパターン

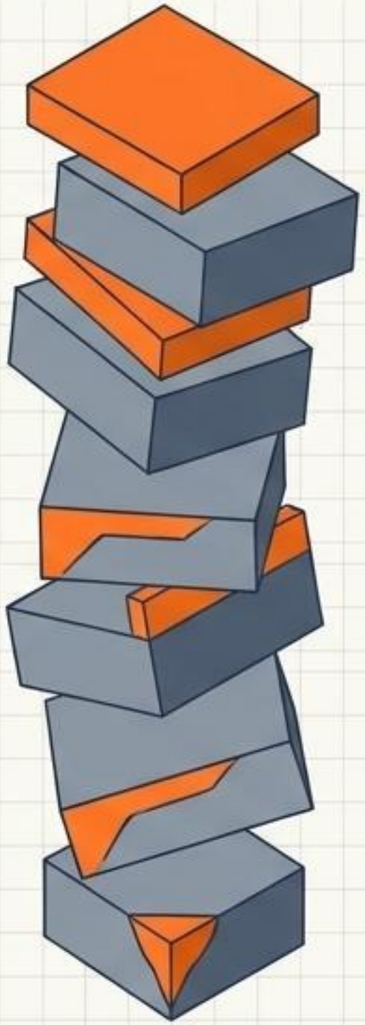
構造の欠陥

動的なデータ（タイムスタンプ、ユーザー入力）をプロンプトの先頭に配置する。



結果

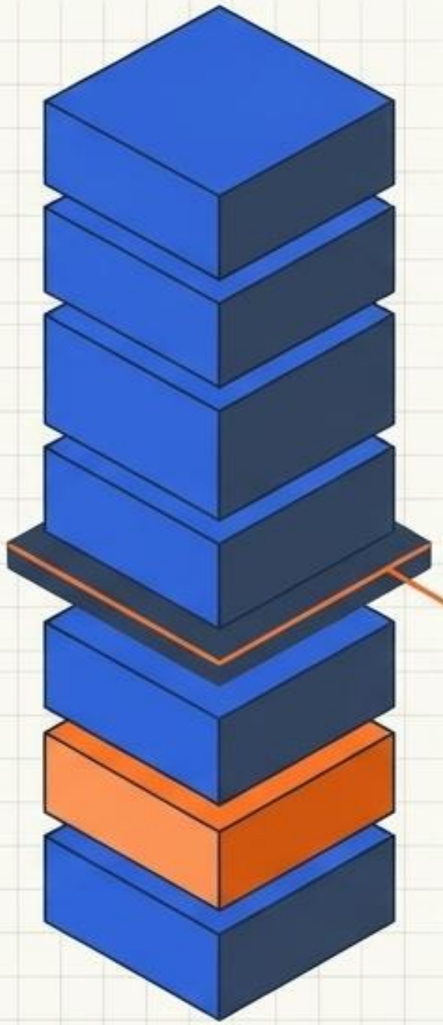
プレフィックスのハッシュが毎回変わり、キャッシュヒット率が0%になる。



ベストプラクティス

構造の最適化

ツール定義、システムプロンプト、静的コンテキストをプロンプトの先頭に集約する。



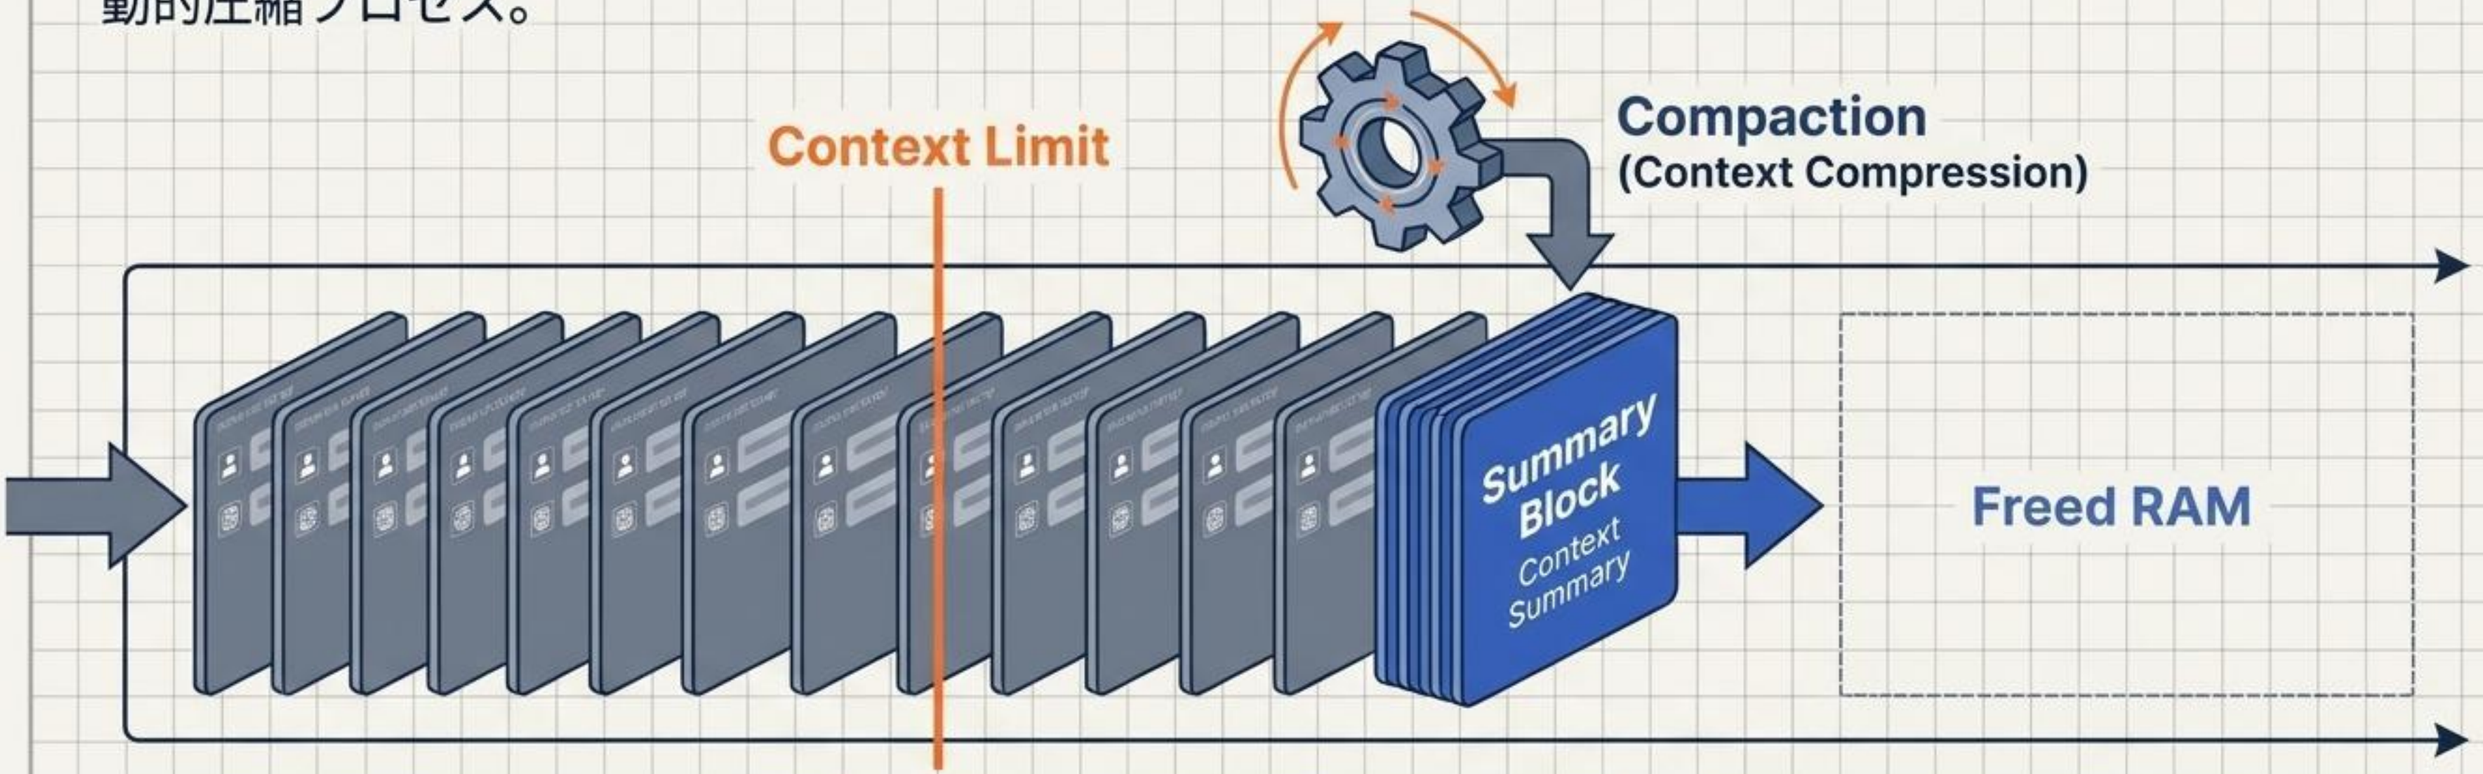
ブレークポイント

変化しない最後のブロックの末尾に cache_control を設定する。

Gemini Notebook

最適化レイヤー 2：コンパクション（文脈の圧縮）

長時間にわたるタスクにおいて、コンテキスト制限を回避しつつ、LLMの一貫性を保つための動的圧縮プロセス。



1. しきい値の検知

会話やトークン数がコンテキストウィンドウの限界に接近したことをシステムが検知。

2. 高忠実度の蒸留

過去のメッセージ履歴をモデル自身に要約させる。冗長な出力は破棄する。

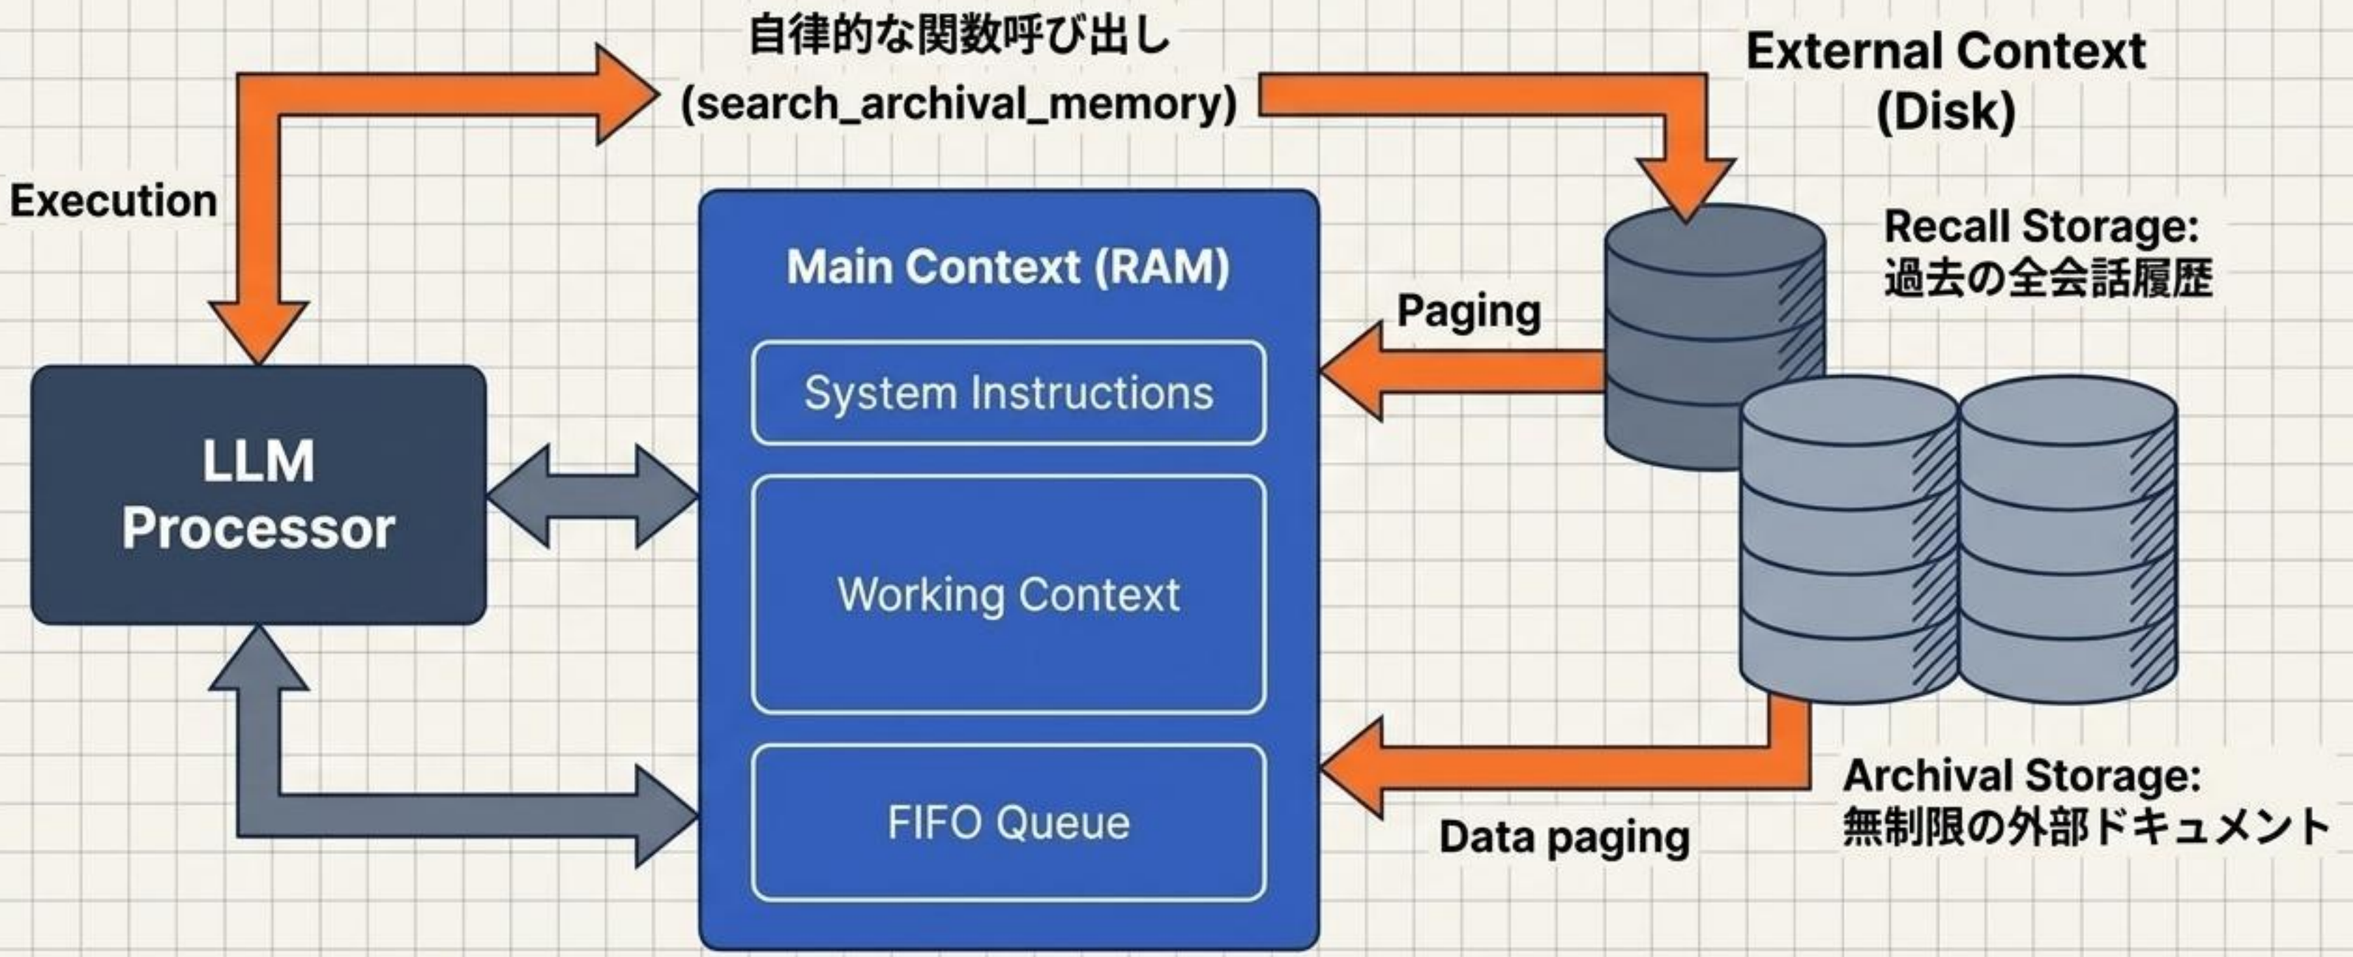
3. ウィンドウのスライド

圧縮されたサマリーと直近の数メッセージのみを新たなコンテキストとして再起動する。

Gemini Notebook

最適化レイヤー３：MemGPTと仮想メモリ管理

LLM自身に「ページング」を行わせることで、物理的なコンテキスト限界を超えた仮想的な無限メモリを提供するアーキテクチャ。



Gemini Notebook

最適化レイヤー 4：サブエージェント構成（コンテキストの隔離）

巨大でノイズの多いコンテキストを処理する際、メインエージェントのアテンションバジェットを汚染しないための分散処理アーキテクチャ。



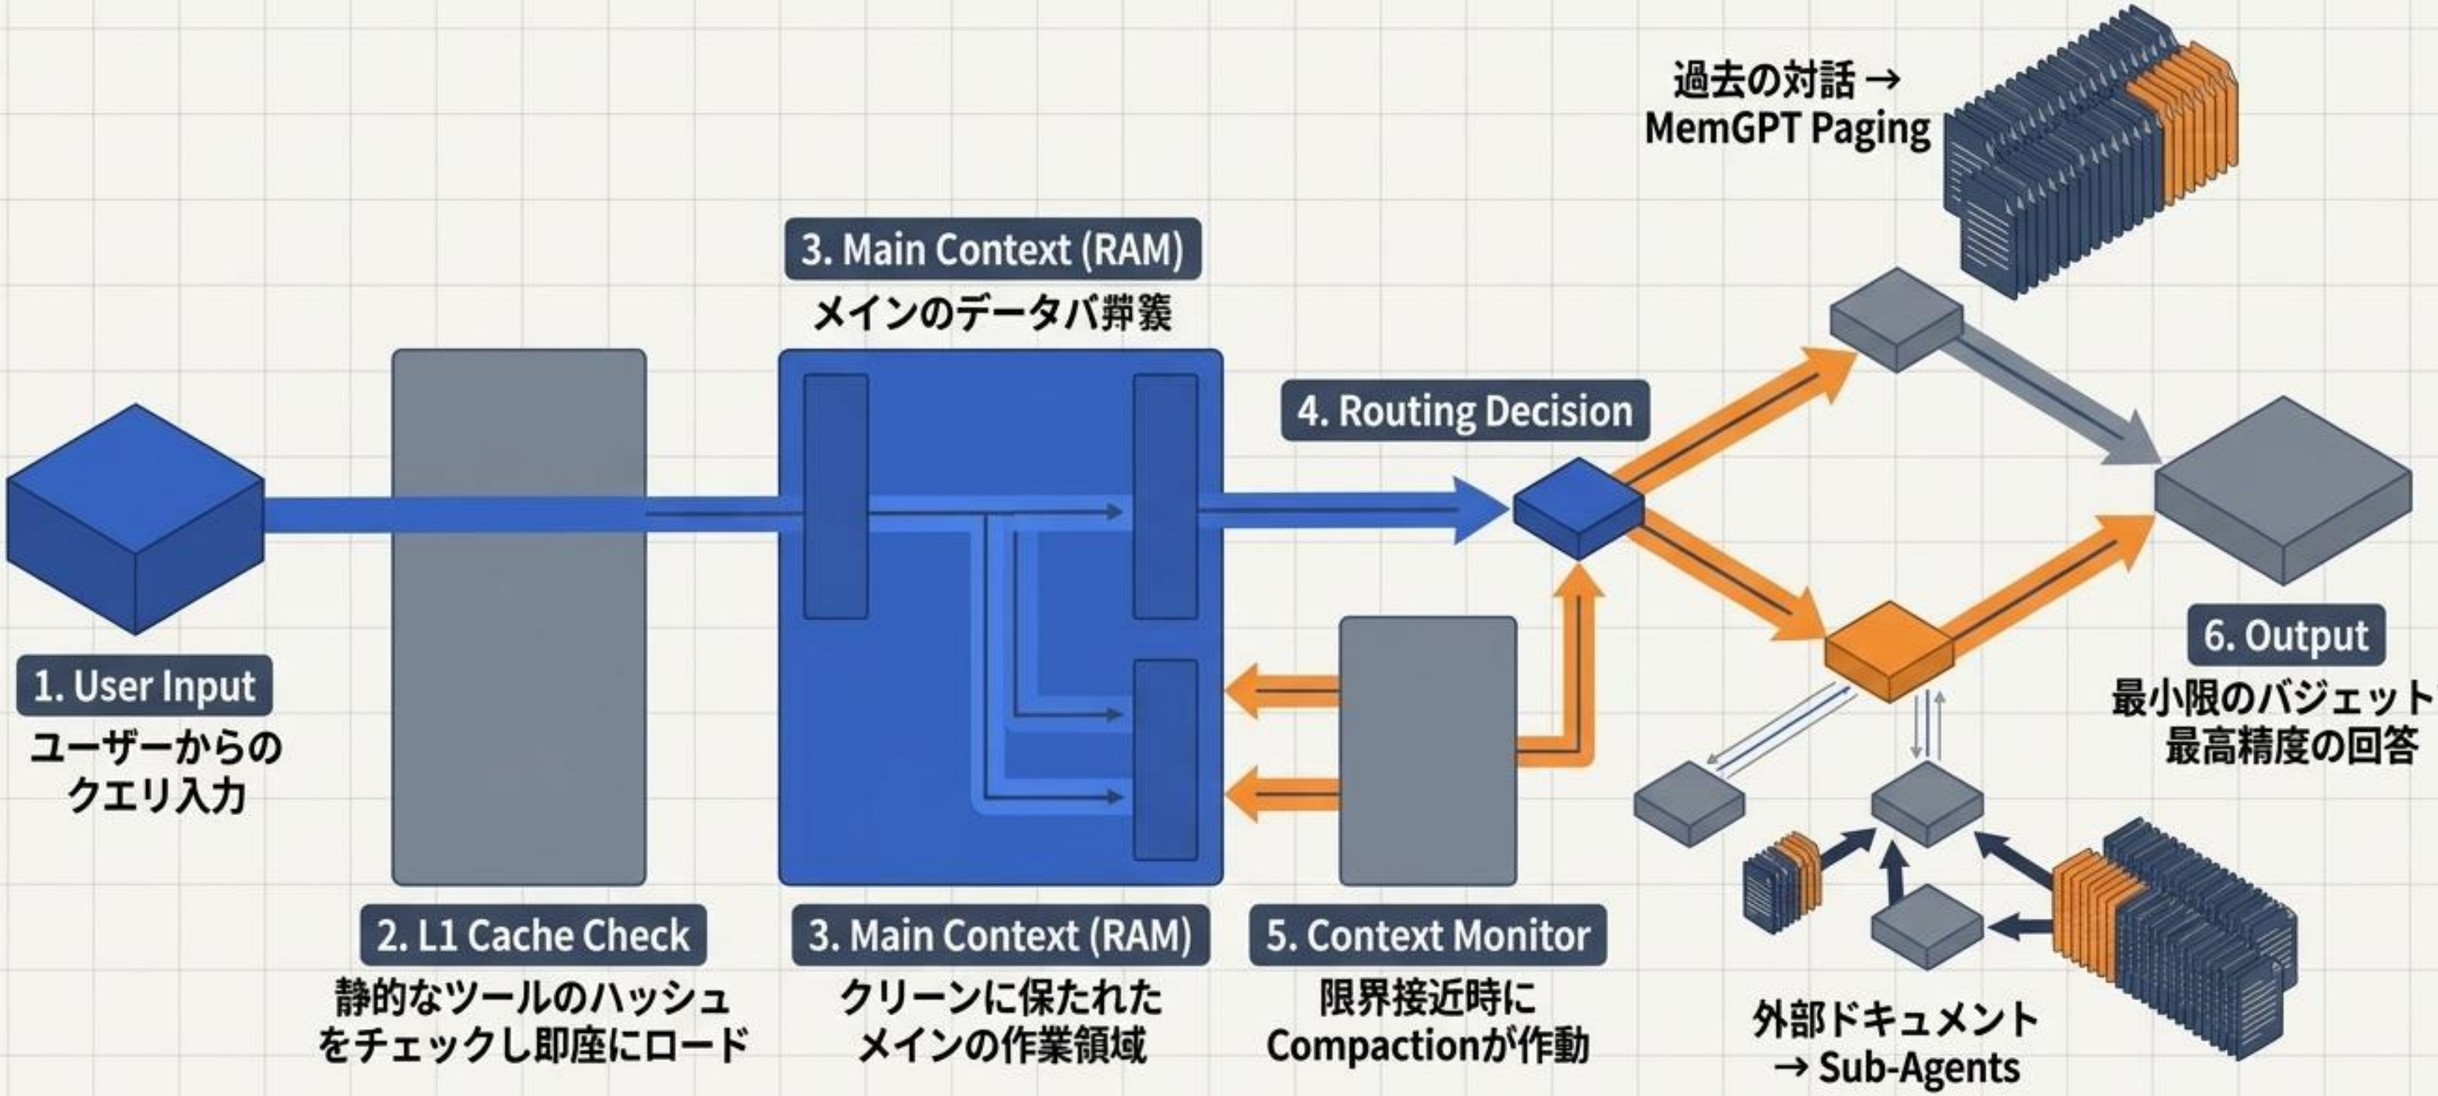
Gemini Notebook

統合戦略：コンテキスト管理マトリクス

戦略	主な目的	トークン効率	実装の複雑さ	最適なユースケース
Prompt Caching	コスト削減とレイテンシの劇的な改善	極めて高い	低	巨大なシステムプロンプト、静的RAG
コンパクション	長期対話における破綻の回避	高	中	連続的なコーディング支援、長時間のチャット
仮想メモリ管理	永久記憶を持つ自律律型エージェントの構築	中	高	パーソナルAIアシスタント、長期稼働の調査
サブエージェント	ノイズの隔離と並列情報処理	低	高	複雑なリサーチ業務、大規模コードベースの移行

Gemini Notebook

次世代AIエージェントの統合アーキテクチャ・ブループリント



Gemini Notebook

結論とテイクアウェイ：Context Engineerへの道



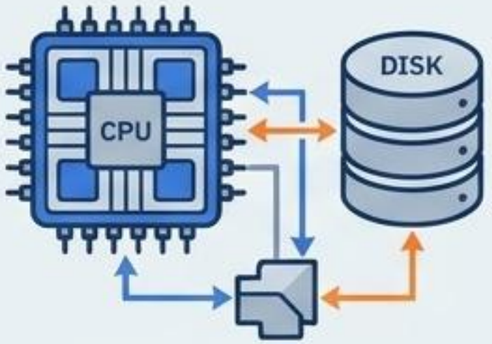
物理法則を尊重する

LLMのコンテキストは有限のアテンションバジェットである。情報を詰め込むほど、推論能力は低下する。



静的と動的を分離する

キャッシュヒット率を最大化するために、静的プレフィックスを先頭に固定し、動的サフィックスを末尾に配置する。



OSのようにシステムを構築する

単一の巨大なプロンプトに頼らず、キャッシュ、RAM、ディスク、コプロセッサを組み合わせた階層的なメモリシステムを設計する。

Gemini Notebook